

# PROJETO II


Previsão de séries temporais

#### Trabalho realizado por:

Ana Patrícia Silva - a22211661

Joana Lopes - a22210868

Tiago Vieira - a22210647



# PROJETO II

Business understanding

Data understanding

Data preparation


Modeling

Evaluation

Forecast

Dimensionality reduction

Next steps



# **BUSINESS UNDERSTANDING**



#### **SALES**

Store ID

Vendas

Product ID

- <u>PRODUCT</u>
- Product ID
- Comprimento
- Largura
- Espessura
- Preço

Stock

- Receitas
- Promoções

#### CITIES


- Store ID
- Tipo de loja
- Tamanho da loja
- País
- Cidade




63 lojas localizadas na Turquia



Dados de vendas de Janeiro 2017 a Setembro 2019





# **BUSINESS UNDERSTANDING**



#### **SALES**

- Store ID
- Product ID
- Vendas
- Stock
- Preço
- Receitas
- Promoções

#### **PRODUCT**

- Product ID
- Comprimento
- Largura
- Espessura

#### **CITIES**

- Store ID
- Tipo de loja
- Tamanho da loja
- País
- Cidade



63 lojas localizadas na Turquia



Dados de vendas de Janeiro 2017 a Setembro 2019





Número de lojas em cada cidade

# **BUSINESS UNDERSTANDING**



#### **SALES**

- Store ID
- Product ID
- Vendas
- Stock
- Preço
- Receitas
- Promoções

#### **PRODUCT**

- Product ID
- Comprimento
- Largura
- Espessura

#### **CITIES**

- Store ID
- Tipo de loja
- Tamanho da loja
- País
- Cidade




63 lojas localizadas na Turquia




Dados de vendas de Janeiro 2017 a Setembro 2019

#### Vendas diárias



#### Lucro diário




2017-01 2017-05 2017-09 2018-01 2018-05 2018-09 2019-01 2019-05 2019-Daily

Classification: Confidential

# NOTA

O número de lojas ao longo do período sofreu flutuações:

- Abertura
- Sazonalidade





# **DATA UNDERSTANDING / DATA PREPARATION**





Table	Sales
Número Variáveis	13
Linhas	8886058
Valores em falta	30.5%
Duplicados	0
Texto	2
Data	1
Variável Categórica	8
Variável Numérica	0


	Vendas diárias											
	store_id	product_id	date	sales	revenue	stock	price	promo_type_1	promo_bin_1	promo_type_2	promo_bin_2	promo_discount_2
1	S0002	P0001	2017- 01-02	0.0	0.00	8.0	6.25	PR14	NaN	PR03	NaN	NaN
2	S0002	P0005	2017- 01-02	0.0	0.00	11.0	33.90	PR14	NaN	PR03	NaN	NaN
3	S0002	P0011	2017- 01-02	0.0	0.00	9.0	49.90	PR14	NaN	PR03	NaN	NaN
4	S0002	P0015	2017- 01-02	1.0	2.41	19.0	2.60	PR14	NaN	PR03	NaN	NaN
5	S0002	P0017	2017- 01-02	0.0	0.00	12.0	1.49	PR14	NaN	PR03	NaN	NaN
	<b>Total rows</b> : 8886058											



Agrupamento semanal das vendas

	store_id	sales	revenue
date			
2017-01-08	S0002	750.232	1813.24
2017-01-15	S0002	871.530	1896.91
2017-01-22	S0002	1069.555	7404.16
2017-01-29	S0002	910.255	2078.39
2017-02-05	S0002	732.754	1745.47
2019-10-06	S0143	18.000	80.82
2019-10-13	S0143	0.000	0.00
2019-10-20	S0143	0.000	0.00
2019-10-27	S0143	0.000	0.00

vendas semanais






Total rows: 8610


Classification: Confidential

# **DATA UNDERSTANDING / DATA PREPARATION**


#### Decomposição da série temporal





#### **Train vs Test**





# **MODELING – SIMPLE AVERAGE**
















# **MODELING - ARIMA**















# **MODELING - ARIMAX**

#### Variáveis exógenas


	store_id	sales	revenue	promo_discount_2	is_holiday	month
date						
2019-09-08	S0002	598.00	6267.91	1.0	0	9
2019-09-15	S0002	656.00	5007.57	1.0	0	9
2019-09-22	S0002	525.00	3074.56	1.0	0	9
2019-09-29	S0002	656.16	5728.25	1.0	0	9
2019-09-08	S0003	227.00	1302.61	1.0	0	9
2019-09-29	S0142	302.00	1866.41	1.0	0	9
2019-09-08	S0143	104.00	915.27	1.0	0	9
2019-09-15	S0143	63.00	507.08	1.0	0	9
2019-09-22	S0143	89.00	601.63	1.0	0	9
2019-09-29	S0143	147.00	704.87	1.0	0	9


**RMSE**<sub>arimax</sub> < **RMSE**<sub>arima</sub> → Efeito positivo das variáveis exógenas



**RMSE**<sub>arimax</sub> > **RMSE**<sub>arima</sub> → Efeito negativo das variáveis exógenas

# **MODELING - ARIMAX**





2500

2000


RMS 1500


1000

500

AVG ARIMA


ARIMAX








# **MODELING - SARIMAX**


#### Introdução de sazonalidade no modelo













# EVALUATION – MÉTRICAS


Escolha dos melhores modelos de previsão para cada loja






### **FORECAST**

#### Previsão do revenue nas 5 semanas seguintes




# <u>Dimensionality Reduction – PCA</u>

- Objetivo: Reduzir o número de lojas em futuras análises
- ☐ Identificar as principais lojas mais contribuem na variância dos dados
- Vantagens:
  - Reduzir tempos de processamento
  - ☐ **Reduzir** número de máquinas de processamento
  - ☐ Facilitar a visualização dos dados e a identificação de tendências ou padrões








Principal component	Variância explicada	Store ID
PC 1	53.6%	S0050
PC 2	5.0%	S0022
PC 3	4.2%	S0041
PC 4	3.4%	S0083

Total ≈ 66%

# <u>Dimensionality Reduction – PCA</u>


#### Análise de correlação entre os 4 componentes principais



Elevadas correlações entre lojas podem indicar:

- Tendências similares de lucro ao longo do tempo
- Lojas pertencem à mesma cidade
- Lojas são do mesmo tipo

#### Hierarchical clustering (daily revenue)



Hierarchical clustering considera os valores diários do lucro para todas as lojas e identifica grupos de dias com tendências similiares de lucro

# **Next steps**

- 1. Melhorar a performance dos modelos de previsão utilizados:
  - Adicionar outras variáveis exógenas
  - > Analisar com mais detalhe a sazonalidade das series temporais
- 2. Testar outros modelos de previsão:
  - Deep learning: RNN / LSTM
- 3. Adicionar mais features ao modelo de clustering de forma a detetar outros padrões:
  - Cidade
  - > Tipo de loja
  - > Tipos de produtos
  - > Número de vendas